

МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
имени М.В.ЛОМОНОСОВА
Механико-математический факультет
Кафедра теории вероятностей

Байесовские методы оценивания в страховании
Bayesian approach in insurance

Курсовая работа
Студента 4 курса 409 группы
Королькова Даниила Александровича

Научный руководитель
доктор физико-математических наук, профессор
Булинская Екатерина Вадимовна

Москва, 2023г.

Содержание

1	Введение	1
2	Оценки MLE и MAP	3
2.1	MLE	3
2.2	MAP	3
2.3	Связь MLE и MAP	5
3	Сопряжённые распределения	5
4	MCMC	7
5	Список литературы	8

1 Введение

Зарождение известной теоремы Байеса можно проследить в его эссе, посвящённом решению одной из задач "Доктрины Случайности" ("The Doctrine of Chances") - первой книге по теории вероятностей впервые опубликованной в 1718 году Муавром. Сегодня под теоремой Байеса мы понимаем следующее выражение

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)},$$

несложно получаемое за два шага из определения условной вероятности.

Определение(Условная вероятность)

Пусть (Ω, F, P) - вероятностное пространство. Пусть $B \in \Omega$ и $P(B) > 0$. Тогда условной вероятностью A при условии B назовём следующее выражение

$$P(A|B) = \frac{P(AB)}{P(B)}.$$

Здесь $P(A)$ - априорная (prior) вероятность, $P(A|B)$ - апостериорная (posterior) вероятность. К слову, $P(B|A)$ может быть интерпретирована, как правдоподобие, а $c = P(B)$ - нормирующий множитель.

Так же отметим, что если множество Ω имеет разбиение (возможно, счётное), то есть $\Omega = \bigsqcup_{i=0}^n B_i$, то $P(A) = \sum_{i=0}^n P(A|B_i)P(B_i)$. Последнее принято называть формулой полной вероятности.

Подобное соотношение распространяется и на плотности, а именно:

$$p(x|y) = \frac{p(y|x)p(x)}{p(y)}.$$

Сегодня школа статистики поделилась на два класса: частотная и байесовская школа. Отличие байесовского подхода заключается в том, что мы заранее делаем предположение о распределении случайной величины. Причём разумно делать такое предположение опираясь на некоторые прошлые наблюдения. Дабы всё стало понятнее, перейдём, наконец, к примеру.

Пример 1

Предположим, что у нас есть некоторый посёлок, в котором уже расположено несколько домов. Новый застройщик решил застраховать свой объект от пожара, который в этом местности не редок. Предлагая ему контракт, мы заранее обговариваем условия возмещений и рассчитываем риски, учитывая три варианта исхода: пожар может быть сильным (θ_1), слабым (θ_2) или не быть вовсе (θ_3). При этом по опыту прошлых лет, нам известно, что сильные пожары бывали в 20% домов, средние - в 30% и в остальных 50% домов пожаров не было вовсе. Иными словами, о случайных величинах $\theta_1, \theta_2, \theta_3$ мы обладаем неким априорным знанием, поэтому на этом этапе мы совершаем предположение о их распределении. Так, $\theta_1 \sim \text{Bern}(p = 0.2), \theta_2 \sim \text{Bern}(0.3), \theta_3 \sim \text{Bern}(0.5)$.

Так же для нашей модели рассмотрим некоторые характеристики (переменные, features), которыми обладают наблюдения (то есть дома). Для упрощения, скажем,

что y_1 - переменная, отвечающая за наличие у дома металлического перекрытия, а y_2 - наличие у дома деревянных окон. Безусловно, на практике рассматриваются не только бинарные переменные, но и непрерывные (скажем, площадь дома) и категориальные (с конечным множеством значений, скажем, количество этажей), тогда вместо вероятностей всюду далее удобнее рассматривать плотности.

Рассмотрим первую характеристику домов. Известно, что металлическое перекрытие было у 10% домов, подвергшихся сильному пожару, 30% домов со средним пожаром и среди тех, кого пожар не затронул, находилось 75% домов с характеристикой $y_1 = 1$.

Рассмотрим вторую характеристику. Известно, что деревянные окна были у 45% домов, окутанных сильным пожаром, 30% домов со средним и среди тех, кого пожар не затронул, было 30% домов характеристикой $y_2 = 1$.

Из полученных наблюдений можно вывести условные вероятности, а именно $P(y_1 = 1|\theta_1 = 1) = 0.1, P(y_1 = 1|\theta_2 = 1) = 0.3, P(y_1 = 1|\theta_3 = 1) = 0.75$ и $P(y_2 = 1|\theta_1 = 1) = 0.45, P(y_2 = 1|\theta_2 = 1) = 0.3, P(y_2 = 1|\theta_3 = 1) = 0.3$. Ясно так же, что вероятность противоположного события $P(y_i = 0|\theta_j) = 1 - P(y_i = 1|\theta_j), i = 1, 2, j = 1, 2, 3$.

Теперь, когда все необходимые наблюдения проведены, можно подходить к расчёту вероятности возгорания нового дома застройщика. Пусть нам известны его характеристики $y_1 = 1$ и $y_2 = 1$ и по ним, лишь по двум переменным, мы и будем предсказывать вероятность возгорания.

$$\begin{aligned}
 P(\theta_1 = 1|y_1 = 1) &= \frac{P(y_1=1|\theta_1=1)P(\theta_1)}{P(y_1=1)} = \frac{P(y_1=1|\theta_1=1)P(\theta_1=1)}{\sum_{i=1}^3 P(y_1=1|\theta_i=1)P(\theta_i=1)} = 0.041, \\
 P(\theta_2 = 1|y_1 = 1) &= \frac{P(y_1=1|\theta_2=1)P(\theta_2)}{P(y_1=1)} = \frac{P(y_1=1|\theta_2=1)P(\theta_2=1)}{\sum_{i=1}^3 P(y_1=1|\theta_i=1)P(\theta_i=1)} = 0.186, \\
 P(\theta_3 = 1|y_1 = 1) &= \frac{P(y_1=1|\theta_3=1)P(\theta_3)}{P(y_1=1)} = \frac{P(y_1=1|\theta_3=1)P(\theta_3=1)}{\sum_{i=1}^3 P(y_1=1|\theta_i=1)P(\theta_i=1)} = 0.773 \\
 P(\theta_1 = 1|y_2 = 1) &= \frac{P(y_2=1|\theta_1=1)P(\theta_1)}{P(y_2=1)} = \frac{P(y_2=1|\theta_1=1)P(\theta_1=1)}{\sum_{i=1}^3 P(y_2=1|\theta_i=1)P(\theta_i=1)} = 0.222, \\
 P(\theta_2 = 1|y_2 = 1) &= \frac{P(y_2=1|\theta_2=1)P(\theta_2)}{P(y_2=1)} = \frac{P(y_2=1|\theta_2=1)P(\theta_2=1)}{\sum_{i=1}^3 P(y_2=1|\theta_i=1)P(\theta_i=1)} = 0.222, \\
 P(\theta_3 = 1|y_2 = 1) &= \frac{P(y_2=1|\theta_3=1)P(\theta_3)}{P(y_2=1)} = \frac{P(y_2=1|\theta_3=1)P(\theta_3=1)}{\sum_{i=1}^3 P(y_2=1|\theta_i=1)P(\theta_i=1)} = 0.556
 \end{aligned}$$

Остюда видим, что наиболее вероятный исход для дома с характеристиками $y_1 = 1$ и $y_2 = 1$ - это третий исход - отсутствие пожара. Более того, это апостериорное наблюдение скорректировало наши априорные знания.

Так, если бы мы рассчитывали наши ожидаемые убытки лишь от этого контракта лишь по одной характеристике j , то необходимо было бы просуммировать стоимости возмещений $(p_1, p_2, p_3$ по каждому из страховых случаев соответственно) с весами вероятностями, т.е. $E(p) = \sum_{i=1}^3 p_i P(\theta_i = 1|y_j = 1)$

Так же, интересным представляется случай, когда переменные $y_i, i = 1, \dots, n$ независимы. В таком случае $P(\theta_j = 1 | y_1 = 1, \dots, y_n = 1) = \frac{P(y_1=1|\theta_j=1) \dots P(y_n=1|\theta_j=1) P(\theta_j=1)}{\sum_{i=1}^3 P(y_1=1|\theta_i=1) \dots P(y_n=1|\theta_j=1) P(\theta_i=1)}$.

2 Оценки MLE и MAP

2.1 MLE

Вспомним содержание метода максимума правдоподобия (Maximum Likelihood Estimation). Если нам известна плотность $p(y|\theta)$ некоторого признака, зависящего от неизвестного параметра θ , то для его оценки необходимо максимизировать $L(\theta|y) := p(y|\theta) = \prod_{i=1}^n p(y_i|\theta)$.

Пример 2

Немного видоизменим наш первый пример и скажем, что пожар может либо случиться, либо нет. Это событие есть ни что иное, как бернуллиевская случайная величина с неизвестным нам параметром $\theta \in \Theta = [0, 1]$. Оценим же вероятность возникновения пожара:

$$\begin{aligned} P(y_i = 1|\theta) &= \theta^{y_i} (1 - \theta)^{1-y_i}, \\ l(\theta|y) = \log(L(\theta|y)) &= \sum_{i=1}^n \log(P(y_i|\theta)) = \sum_{i=1}^n y_i \log \theta + (1 - y_i) \log(1 - \theta) \rightarrow \max_{\theta \in \Theta} \\ \hat{\theta}_{MLE} &= \frac{1}{n} \sum_{i=1}^n y_i \end{aligned}$$

Такая оценка получена после логарифмирования (именно это монотонное преобразование упрощает поиск экстремума) и дифференцирования экстремального выражения по параметру θ и приравнивания результата к нулю. Оценка полученная таким путём достаточно проста и очевидна: если хотим оценить вероятность пожара, то достаточно просто взять среднее арифметическое всех наблюдаемых исходов ранее. Однако, если наших наблюдений было мало, то скорее всего будет перевес в какую-то сторону, скажем, если в 9 случаях из 10 был пожар, то такая оценка выдаст значение $\frac{9}{10}$, что может быть далеко от истины. Словом, как и для любой состоятельной оценки нам необходимо достаточно много наблюдений.

2.2 MAP

В Байсовском же подходе дела обстоят несколько иначе. Предположим, что мы не обладаем никаким знанием о истинном распределении параметра θ и можем лишь предположить, что априорное распределение равномерное и $p(\theta) = 1$ на $[0, 1]$. Пускай мы пронаблюдали лишь за одним домом в нашем посёлке и в нём пожар произошёл, то есть $p(y|\theta) = \theta$.

Теперь же несложно найти и апостериорную плотность, зная, что $p(y) = \frac{1}{2}$. Так по формуле Байеса получим $p(\theta|y) = 2\theta$

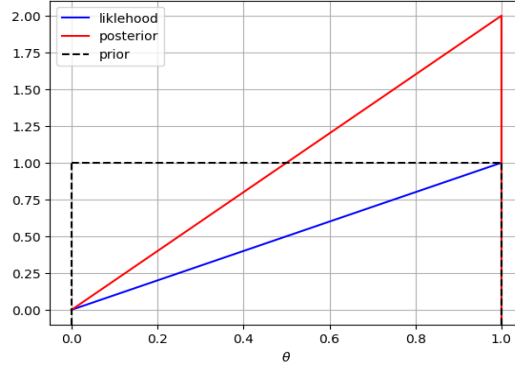


Рис. 1: Распределение неизвестного параметра

Теперь перейдём ко второму дому в нашем посёлке и теперь, вместо того, чтобы доверять первоначальному априорному распределению $p(\theta) = 1$, возьмём в качестве нового априорного распределения только что полученное апостериорное. Пусть во втором доме пожара-таки не было, то есть $p(y|\theta) = 1 - \theta$. Тогда

$$p(\theta|y) = \frac{p(y|\theta)p(\theta)}{\int_{\theta} p(y|\theta)p(\theta)d\theta} = 6\theta * (1 - \theta)$$




Рис. 2: После второго наблюдения

Ну и для большей удовлетворённости перейдём к третьему дому. Откалибруем вновь априорное распределение $p(\theta) = 6\theta * (1 - \theta)$, пожара в нём не было, т.е. $p(y|\theta) = 1 - \theta$ и несложными вычислениями получаем

$$p(\theta|y) = 12\theta(1 - \theta)^2$$

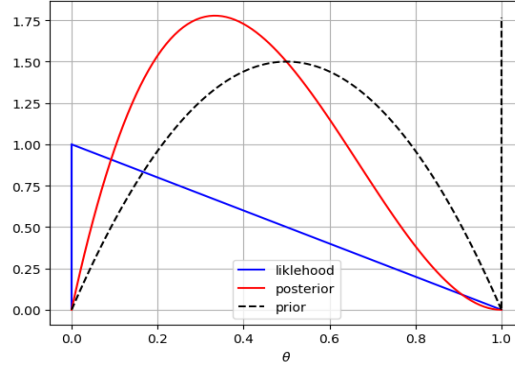


Рис. 3: После третьего наблюдения

Так, проделав несколько итераций, мы уже можем заметить отличие от MLE - сейчас мы работали с распределениями и наши оценки - распределения, в то время как метод максимального правдоподобия - точечное оценивание и его оценка - некий скаляр. И чтобы сейчас ответить на вопрос, какое θ выбрать, воспользуемся максимизацией постериорного распределения (Maximum a posteriori = MAP). Подобно MLE, прологарифмируем плотность и найдём критическую точку:

$$\begin{aligned} \log p(\theta|y) &= \log p(y|\theta) + \log p(\theta) - \log(y) \rightarrow \max_{\theta \in \Theta} \quad (*) \\ &\quad \sim \\ &= \log p(y|\theta) + \log p(\theta) \rightarrow \max_{\theta \in \Theta} \end{aligned}$$

То есть та же задача максимизация правдоподобия плюс некий добавок в виде априорного распределения.

2.3 Связь MLE и MAP

Ясно, что MLE является частным случаем MAP. Действительно, если бы априорное распределение не зависело от θ (например, так, как это было в первой итерации), то и задача (*) была бы эквивалентна задаче максимизации правдоподобия

3 Сопряжённые распределения

В примере выше на каждом новом шаге мы получали новое распределение. На самом деле, мы получали Бета-распределение. Напомню, что это распределение случайной величины X с параметрами $\alpha, \beta > 0$ и плотностью вида:

$$\begin{aligned} f_X(x) &= \frac{x^{\alpha-1}(1-x)^{\beta-1}}{B(\alpha, \beta)}, \\ B(\alpha, \beta) &= \int_0^1 x^{\alpha-1}(1-x)^{\beta-1} dx \end{aligned}$$

Вот примеры некоторых Бета-распределений:




Рис. 4: Плотности Бета-распределения

В случае Бета-распределения получим следующую оценку:

$$\hat{\theta}_{MAP} = \frac{\sum_{i=1}^n y_i + (\alpha - 1)}{m + (\alpha - 1) + (\beta - 1)}$$

И кажется, что на каждом шаге вычислений, нам не составит труда посчитать числитель в формуле Байеса и найти оценку неизвестного параметра, не смотря на то, что в знаменателе может стоять выражение, подсчёт которого может быть сильно затруднён. Так вот как раз, чтобы таких проблем не возникало и результат подсчёта апостериорного распределения мог бы использоваться в следующей итерации, как априорное, стоит обратить внимание на так называемые сопряжённые распределения - такое семейство пар, которые не выводят нас из класса априорного распределения (как в этом случае Бернулли и Бета-распределения).

Определение

Пусть $x \sim \mathcal{O}(\theta)$, $\theta \sim \mathcal{B}(\beta_0)$. Тогда семейства \mathcal{O} и \mathcal{B} называются сопряжёнными, если $p(\theta|x) \sim \mathcal{B}(\beta_1)$

Вот некоторые из распространённых пар сопряжённых распределений:

- $p(y|\theta)$ - распределение Бернулли с параметром θ , $p(\theta)$ - Бета-распределение.
- $p(y|\mu)$ - нормальное с некоторым матожиданием μ и фиксированной дисперсией σ^2 , и $p(\theta)$ - нормальное.
- $p(y|\lambda)$ - показательное с параметром λ , $p(\lambda)$ - Гамма-распределение
- $p(y|\lambda)$ - пуассоновское с параметром λ , $p(\lambda)$ - Гамма-распределение
- $p(y|\theta)$ - равномерное на отрезке $[0, \theta]$, $p(\theta)$ - Парето

Зачастую легче работать с экспоненциальным классом распределений, для него всегда удобно подбирать сопряжённое $p(\theta)$. К слову, большинство перечисленных выше распределений как раз-таки экспоненциальные.

4 MCMC

5 Список литературы

- [1] Учебник по машинному обучению. Глава: 4.6. Байесовский подход к оцениванию.
- [2] А.Г.Дьяконов. “Анализ малых данных“, глава: Байесовский подход.
- [3] Christopher M. Bishop. “Pattern Recognition and Machine Learning“
- [4] Alexandra Hotti. “Bayesian insurance pricing using informative prior estimation techniques“.